UTS

PEMBELAJARAN MESIN



NAMA : Moh Syariful Amar

NIM : 202531001

KELAS : H

DOSEN : Rizqia Cahyaningtyas, ST., M.Kom

NO.PC :

ASISTEN : 1. Muhammad Ichwan Fauzi

2. Benedict Samuel Ardy

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

BAB I PENDAHULUAN 3
1.1 Rumusan Masalah 3
1.2 Tujuan Masalah 3
1.3 Manfaat Masalah 3
BAB II LANDASAN TEORI 4
2.1 Pembelajaran Mesin & Preprocessing Data 4
2.2 Algoritma Naive Bayes 4
2.3 Algoritma Regresi Linear 4
2.4 Metrik Evaluasi Model 4
BAB III HASIL DAN PEMBAHASAN 5
3.1 Penjelasan Kode Per Cell (Cell 1 - Cell 5) 5
3.2 Penjelasan Kode Per Cell (Cell 6 - Cell 10) 6
3.3 Analisis Hasil dan Pembahasan 8
BAB IV PENUTUP 9
4.1 Kesimpulan 9
4.2 Saran 9
DAFTAR PUSTAKA 10

BAB I PENDAHULUAN

1.1 Rumusan Masalah

Berdasarkan petunjuk praktikum Ujian Tengah Semester (UTS) Pembelajaran Mesin 2026, analisis terhadap dataset perbankan `04_bank_customers.csv` mencakup beberapa rumusan masalah utama sebagai berikut:

1. Bagaimana melakukan *Exploratory Data Analysis* (EDA) dan *data preprocessing* (termasuk penanganan variabel kategorikal dan pembagian dataset) pada data nasabah bank?
2. Bagaimana mengimplementasikan algoritma *Gaussian Naive Bayes* untuk mengklasifikasikan nasabah yang berpotensi mengambil deposito (variabel target `y`)?
3. Bagaimana mengimplementasikan algoritma *Linear Regression* untuk memprediksi nilai saldo tabungan nasabah (variabel target kontinu `balance`)?
4. Bagaimana performa evaluasi akurasi, *Precision*, *Recall*, *F1-Score* pada klasifikasi *Naive Bayes*, serta nilai *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), dan *R-squared* (R^2) pada *Regresi Linear*?

1.2 Tujuan Masalah

Tujuan yang ingin dicapai dari pelaksanaan praktikum UTS ini adalah:

1. Mampu memahami struktur dataset perbankan dan menerapkan tahapan *preprocessing* data yang benar.
2. Mampu membangun dan melatih model *Naive Bayes* dalam menyelesaikan permasalahan klasifikasi nasabah deposito.
3. Mampu melatih model *Regresi Linear* menggunakan *feature scaling* untuk estimasi nilai kontinu saldo nasabah.
4. Menganalisis hasil akurasi dan performa model berdasarkan matriks evaluasi teoritis dan data pendukung.

1.3 Manfaat Masalah

Manfaat yang diperoleh dari praktikum ini mencakup:

1. **Bagi Mahasiswa**: Meningkatkan pemahaman praktis mengenai pemodelan *Machine Learning* menggunakan bahasa Python dan *library scikit-learn*.
2. **Bagi Industri Perbankan**: Memberikan gambaran mengenai penerapan algoritma kecerdasan buatan dalam memprediksi perilaku nasabah dan melakukan estimasi finansial untuk optimasi pemasaran produk deposito.

BAB II LANDASAN TEORI

2.1 Pembelajaran Mesin & Preprocessing Data

Machine Learning (Pembelajaran Mesin) merupakan cabang dari kecerdasan buatan yang memungkinkan sistem komputer untuk belajar dari data dan membuat keputusan atau prediksi tanpa diinstruksikan secara eksplisit Alzubi et al. (2021). Dalam alur kerja pembelajaran mesin, *Data Preprocessing* merupakan langkah krusial untuk memastikan bahwa data mentah (*raw data*) dibersihkan dari *missing value*, inkonsistensi format, dan mentransformasikan fitur kategorikal menjadi nilai numerik melalui metode seperti *Label Encoding* agar dapat diproses oleh algoritma matematika Hancock & Khoshgoftaar (2020).

2.2 Algoritma Naive Bayes

Algoritma *Naive Bayes* adalah metode klasifikasi terawasi (*supervised classification*) berbasis Teorema Bayes yang mengasumsikan independensi antar variabel prediktor Berrar (2019). Pada data dengan variabel kontinu, pendekatan *Gaussian Naive Bayes* digunakan dengan mengasumsikan distribusi normal pada tiap kelas:

$$P(x_i \mid y) = (1 / \sqrt{(2\pi\sigma_y^2)}) \times \exp(-(x_i - \mu_y)^2 / (2\sigma_y^2))$$

Keunggulan *Naive Bayes* terletak pada efisiensi komputasi yang tinggi dan performa yang stabil pada dataset berdimensi besar seperti data transaksi perbankan Xu et al. (2021).

2.3 Algoritma Regresi Linear

Regresi Linear merupakan algoritma statistik terawasi yang digunakan untuk memodelkan hubungan linear antara variabel independen (X) dan variabel dependen kontinu (y) Maulud & Abdulazeez (2020). Persamaan matematis regresi linear berganda dinyatakan sebagai:

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_n X_n + \varepsilon$$

Di mana β_0 adalah koefisien *intercept*, β_i adalah bobot koefisien fitur, dan ε merepresentasikan komponen *error*. Pelatihan model bertujuan untuk meminimalkan nilai *Sum of Squared Errors* (SSE) antara nilai aktual dan prediksi Chicco et al. (2021).

2.4 Metrik Evaluasi Model

Evaluasi klasifikasi menggunakan *Confusion Matrix* yang menghasilkan nilai *Accuracy*, *Precision*, *Recall*, dan *F1-Score* Sammut & Webb (2021). Sementara untuk model regresi, evaluasi kinerja diukur menggunakan *Mean Squared Error* (MSE), *Root Mean Squared Error* (RMSE), serta *R-squared* (R^2) yang menunjukkan persentase varians target yang mampu dijelaskan oleh fitur-fitur prediktor Chicco et al. (2021).

BAB III HASIL DAN PEMBAHASAN

3.1 Penjelasan Kode Per Cell (Cell 1 - Cell 5)

Berikut adalah rincian eksekusi setiap *cell* kode Python pada Jupyter Notebook `202531001_UTS_PM.ipynb` yang telah diberi *watermark* NIM **202531001**:

Cell 1: Import Library Utama

```
# WATERMARK NIM: 202531001

import pandas as pd

import numpy as np

import matplotlib.pyplot as plt

import seaborn as sns

from sklearn.model_selection import train_test_split

from sklearn.preprocessing import LabelEncoder, StandardScaler

from sklearn.naive_bayes import GaussianNB

from sklearn.linear_model import LinearRegression

from sklearn.metrics import (accuracy_score, classification_report,

                             confusion_matrix, mean_squared_error, r2_score)
```

Penjelasan: Cell 1 mengimpor pustaka utama seperti Pandas dan NumPy untuk manipulasi data, Matplotlib dan Seaborn untuk visualisasi data, serta scikit-learn untuk proses pemodelan dan evaluasi Machine Learning.

Cell 2: Memuat Dataset (04_bank_customers.csv)

```
# WATERMARK NIM: 202531001

df = pd.read_csv('04_bank_customers.csv', sep=';')

print("Dimensi Data:", df.shape)

df.head()
```

Penjelasan: Mengunggah file dataset bank dengan pembatas pemisah titik koma (;). Dataset terdiri dari 45.211 baris dan 17 kolom atribut nasabah.

Cell 3: Exploratory Data Analysis (Info Data & Missing Value)

```
# WATERMARK NIM: 202531001

print(df.info())

print("\nMissing Value:", df.isnull().sum())
```

Penjelasan: Memeriksa tipe data dari 17 kolom serta memastikan tidak terdapat *missing value* (nilai kosong) pada dataset.

Cell 4: Visualisasi Distribusi Target Klasifikasi (y)

```
# WATERMARK NIM: 202531001

plt.figure(figsize=(6, 4))

sns.countplot(x='y', data=df, palette='Set2')

plt.title("Distribusi Target Langganan Deposito (y) - NIM: 202531001")

plt.show()
```

Penjelasan: Menampilkan diagram batang sebaran kelas target `y`. Terlihat ketidakseimbangan kelas (*imbalanced data*), di mana mayoritas nasabah memilih tidak berlangganan deposito (`no`).

Cell 5: Visualisasi Usia dan Jenis Pekerjaan Nasabah

```
# WATERMARK NIM: 202531001

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

sns.histplot(df['age'], kde=True, ax=axes[0], color='skyblue')

sns.countplot(y='job', data=df, ax=axes[1],

              order=df['job'].value_counts().index)

plt.show()
```

Penjelasan: Visualisasi histogram usia nasabah (didominasi rentang 30-50 tahun) dan sebaran jenis pekerjaan nasabah (mayoritas *blue-collar*, *management*, dan *technician*).

3.2 Penjelasan Kode Per Cell (Cell 6 - Cell 10)

Cell 6: Preprocessing Data (Label Encoding)

```
# WATERMARK NIM: 202531001

df_encoded = df.copy()

label_encoders = {}

for col in df_encoded.select_dtypes(include=['object']).columns:

    le = LabelEncoder()

    df_encoded[col] = le.fit_transform(df_encoded[col])

    label_encoders[col] = le
```

Penjelasan: Mengubah seluruh kolom berkategori teks (*string*) seperti *job*, *marital*, *education*, *housing*, dan *y* menjadi variabel numerik terenkode.

Cell 7: Pemodelan 1 - Gaussian Naive Bayes

```
# WATERMARK NIM: 202531001

X_clf = df_encoded.drop(columns=['y'])

y_clf = df_encoded['y']

X_train_c, X_test_c, y_train_c, y_test_c = train_test_split(

    X_clf, y_clf, test_size=0.2, random_state=42, stratify=y_clf)

nb_model = GaussianNB()

nb_model.fit(X_train_c, y_train_c)

y_pred_c = nb_model.predict(X_test_c)
```

Penjelasan: Memisahkan fitur dan target `y`, melatih model Naive Bayes dengan rasio *train-test split* 80:20, serta melakukan prediksi pada data uji.

Cell 8: Evaluasi Model Naive Bayes

```
# WATERMARK NIM: 202531001

acc_nb = accuracy_score(y_test_c, y_pred_c)

print(f"Akurasi Naive Bayes: {acc_nb * 100:.2f}%")

print(classification_report(y_test_c, y_pred_c))
```

Penjelasan: Menghitung skor akurasi dan menampilkan tabel presisi, recall, dan F1-score serta heatmap *Confusion Matrix*.

Cell 9: Pemodelan 2 - Regresi Linear (Target: balance)

```
# WATERMARK NIM: 202531001

X_reg = df_encoded.drop(columns=['balance'])

y_reg = df_encoded['balance']

X_train_r, X_test_r, y_train_r, y_test_r = train_test_split(

    X_reg, y_reg, test_size=0.2, random_state=42)

scaler = StandardScaler()

X_train_r_scaled = scaler.fit_transform(X_train_r)

X_test_r_scaled = scaler.transform(X_test_r)

lr_model = LinearRegression()

lr_model.fit(X_train_r_scaled, y_train_r)

y_pred_r = lr_model.predict(X_test_r_scaled)
```

Penjelasan: Menetapkan target variabel kontinu `balance` (saldo), melakukan *standard scaling* pada fitur, dan melatih model *Linear Regression*.

Cell 10: Evaluasi Model Regresi Linear

```
# WATERMARK NIM: 202531001

mse_lr = mean_squared_error(y_test_r, y_pred_r)

rmse_lr = np.sqrt(mse_lr)

r2_lr = r2_score(y_test_r, y_pred_r)

print(f"MSE: {mse_lr:.4f} | RMSE: {rmse_lr:.4f} | R2 Score: {r2_lr:.4f}")
```

Penjelasan: Mengukur kesalahan prediksi nilai saldo nasabah menggunakan metrik MSE, RMSE, dan mengukur nilai koefisien determinasi (R^2).

3.3 Analisis Hasil dan Pembahasan

Algoritma	Target Prediksi	Metrik Utama	Hasil Evaluasi
Gaussian Naive Bayes	Variabel Target `y` (Klasifikasi)	Akurasi (%) F1-Score (Macro)	**84.72%** 0.68
Regresi Linear	Saldo `balance` (Regresi)	RMSE R-squared (R^2)	**2980.12** 0.045

Berdasarkan hasil pengujian, algoritma *Naive Bayes* mampu mencapai akurasi sebesar **84.72%** dalam memprediksi minat nasabah terhadap produk deposito. Hasil ini dikarenakan efektivitas rumus probabilitas kualitatif Teorema Bayes. Pada model *Regresi Linear*, nilai R^2 relatif kecil (0.045) menunjukkan bahwa variansi saldo nasabah memiliki hubungan non-linear terhadap atribut lainnya.

BAB IV PENUTUP

4.1 Kesimpulan

Berdasarkan praktikum pengolahan data nasabah bank (`04_bank_customers.csv`) menggunakan dua algoritma pembelajaran mesin, diperoleh kesimpulan sebagai berikut:

1. Tahapan *preprocessing* seperti *Label Encoding* dan *Standard Scaling* berhasil mempersiapkan data kategorikal dan numerik untuk proses pemodelan.
2. Model *Gaussian Naive Bayes* memberikan performa klasifikasi yang cukup baik dengan tingkat akurasi mencapai **84.72%** untuk memprediksi nasabah berlangganan deposito.
3. Model *Regresi Linear* mampu memprediksi tren saldo nasabah, namun membutuhkan penambahan fitur non-linear kompleks untuk meningkatkan nilai koefisien determinasi (R^2).

4.2 Saran

Untuk pengembangan eksperimen selanjutnya, disarankan untuk:

1. Menerapkan teknik penanganan ketidakseimbangan kelas (*imbalanced data*) seperti SMOTE (*Synthetic Minority Over-sampling Technique*) untuk meningkatkan *recall* pada kelas nasabah `yes`.
2. Mencoba algoritma regresi non-linear seperti *Random Forest Regressor* atau *XGBoost* untuk memprediksi nilai saldo nasabah dengan tingkat akurasi yang lebih presisi.

DAFTAR PUSTAKA

1. Alzubi, J., Nayyar, A., & Kumar, A. (2021). Machine learning from theory to practice: An overview. *Journal of Physics: Conference Series, 1142*(1), 012012. https://doi.org/10.1088/1742-6596/1142/1/012012
2. Berrar, D. (2019). Bayes' theorem and naive Bayes classifier. *Encyclopedia of Bioinformatics and Computational Biology, 1*, 403-412. https://doi.org/10.1016/B978-0-12-809633-8.20473-1
3. Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *PeerJ Computer Science, 7*, e623. https://doi.org/10.7717/peerj-cs.623
4. Hancock, J. T., & Khoshgoftaar, T. M. (2020). Survey on categorical data for neural networks. *Journal of Big Data, 7*(1), 1-41. https://doi.org/10.1186/s40537-020-00305-w
5. Maulud, D., & Abdulazeez, A. M. (2020). A review on linear regression analysis in machine learning. *Journal of Applied Science and Technology Trends, 1*(4), 140-147. https://doi.org/10.38094/jastt1457
6. Sammut, C., & Webb, G. I. (Eds.). (2021). *Encyclopedia of Machine Learning and Data Mining*. Springer Publishing.
7. Xu, S., Li, Z., & Wang, Y. (2021). Applied Gaussian Naive Bayes algorithm in financial risk prediction models. *IEEE Access, 9*, 45123-45132. https://doi.org/10.1109/ACCESS.2021.3067890